

FAMILY BASKET ANALYSIS

Análisis Exploratorio de Precios de la Canasta Familiar

Región Eje Cafetero, Colombia 2022–2025

INFORME TRABAJO FINAL

Programación en Ciencia de Datos



Presentado por

Barranco Hassan
Marquez Cortés Yirleidis
Tirado Melani

Docente

PhD. Ernesto Amaru Galvis

Santa Marta, Colombia
Junio de 2026

Tabla de contenido


1. Introducción y Contexto del Proyecto	3
2. Objetivos	3
Objetivo general:	3
Objetivos específicos:.....	4
3. Identificación y Justificación de la Fuente de Datos	4
Preguntas analíticas	5
4. Metodología y estructura del programa	5
5. Procesamiento y Calidad de Datos (ETL)	8
6. Enriquecimiento y Generación de Métricas Analíticas	8
7. Análisis Exploratorio de Datos	9
8. Visualización e Interpretación de Resultados.....	11
8.1 Evolución Temporal del Índice de Precios	11
8.2 Comparación entre Ciudades.....	13
8.3 Volatilidad de Precios por Categoría.....	14
9. Respuestas a las Preguntas Analíticas	15
10. Uso de Inteligencia Artificial Generativa	16
11. Conclusiones	16
12. Referencias.....	17

1. Introducción y Contexto del Proyecto

Para el presente trabajo nuestro grupo seleccionó el dataset Histórico de Precios Producto de la Canasta Familiar RAP Eje Cafetero, publicado en el Portal de Datos Abiertos de Colombia (datos.gov.co). Este dataset contiene información sobre los precios registrados en mercados de ciudades del Eje Cafetero colombiano, lo que permite estudiar el comportamiento de los precios de productos de primera necesidad a lo largo del tiempo.

El desarrollo del proyecto contempla la carga, limpieza, complementación y visualización de los datos, todo ello implementado en un programa de Python. El presente informe describe en detalle cada etapa del proceso analítico, las decisiones tomadas y los resultados obtenidos.

Este documento se estructura en cinco etapas, como se describe en la siguiente ilustración:



Nota 1. Elaboración de los autores con Napkin AI

2. Objetivos

Objetivo general

Aplicar el flujo completo de un análisis exploratorio de datos en Python sobre un conjunto de datos público y oficial, para estudiar el comportamiento de los precios de la canasta familiar en el Eje Cafetero entre septiembre de 2022 y septiembre de 2025.

Objetivos específicos

- Seleccionar y justificar un dataset del Portal de Datos Abiertos de Colombia que supere los 8.000 registros y requiera preparación.
- Cargar el dataset, verificar su estructura y corregir los problemas de calidad detectados.
- Enriquecer los datos con columnas derivadas que permitan comparar la variabilidad de precios entre productos, ciudades y categorías.
- Realizar la exploración estadística y el análisis comparativo entre grupos (ciudades y categorías).
- Construir e interpretar al menos tres visualizaciones que respondan las preguntas analíticas planteadas.
- Documentar y reflexionar sobre el uso de inteligencia artificial generativa en el desarrollo del programa.

3. Identificación y Justificación de la Fuente de Datos

La base del análisis es el conjunto de datos "Histórico de Precios Producto de la Canasta Familiar RAP Eje Cafetero", obtenido del Portal de Datos Abiertos de Colombia (datos.gov.co):

https://www.datos.gov.co/Agricultura-y-Desarrollo-Rural/Historico-de-Precios-Productos-de-la-Canasta-Famil/gdqq-rry2/about_data

Descripción del Dataset

- **Volumen:** 83.813 registros.
- **Fuente:** Histórico de Precios Producto de la Canasta Familiar RAP Eje Cafetero.
- **Variables principales:** Productos, Mercados, Precio_mínimo, Precio_máximo, Precio_medio, Fecha_inicial, Fecha_final, Categoría y Ciudad. El dataset cubre cuatro ciudades (Armenia, Ibagué, Manizales y Pereira), 8 categorías y 213 productos distintos, con registros entre septiembre de 2022 y septiembre de 2025.

Justificación: se eligió este dataset por su relación directa con el costo de vida en el Eje Cafetero y porque permite analizar series de tiempo. Cumple además los criterios del trabajo: supera los 8.000 registros (83.813) y exige limpieza real antes de poder analizarse, ya que los precios y las fechas vienen como texto.

Preguntas analíticas

Antes de iniciar el análisis, el grupo formuló las siguientes preguntas analíticas que orientaron el proceso exploratorio:


- ¿Cómo evoluciona el índice de precios de los productos de la canasta familiar en el tiempo?
- ¿Qué ciudades del Eje Cafetero presentan mayores niveles de precios?
- ¿Qué categorías de productos muestran mayor variabilidad o volatilidad en sus precios?
- ¿Qué tan amplia es la diferencia entre los precios mínimos y máximos reportados dentro de un mismo registro?
- ¿Qué utilidad ofrecen las columnas derivadas para comparar productos, ciudades y categorías en términos de variabilidad de precios?

Estas preguntas guiaron tanto las decisiones de limpieza y complementos como la selección de las visualizaciones generadas por el programa.

4. Metodología y estructura del programa

El programa fue desarrollado en Python, siguiendo un diseño por módulos que separa la lógica de análisis de la interfaz de usuario. La estructura del proyecto es la siguiente:

Estructura de los Archivos



Nota 2 Elaboración de los autores con Napkin AI

- main.py: archivo principal que coordina la ejecución del flujo completo.
- src/config.py: constantes del proyecto (rutas, nombres de columnas, diccionarios de transformación).
- src/pipeline.py: lógica de limpieza y enriquecimiento del dataset.
- src/utils.py: funciones auxiliares como carga del archivo y medición de tiempos.
- src/cli.py: funciones para mostrar información en consola (interfaz de usuario).
- src/visualizations.py: generación y almacenamiento de gráficas.
- data/: carpeta que contiene el archivo CSV del dataset.
- figures/: carpeta donde se guardan las visualizaciones generadas.
- README.md: documentación del repositorio.

- pyproject.toml: configuración del proyecto y dependencias.

Flujo de ejecución

El archivo main.py ejecuta el flujo completo del análisis en el siguiente orden:



Nota 3 Elaboración de los autores con Napkin AI

Verificación de la estructura inicial

La estructura confirma 83.813 registros y 9 columnas, todas cargadas inicialmente como texto y sin valores nulos. Por eso el trabajo no fue imputar ni eliminar registros, sino corregir tipos de datos y formatos, el resumen estadístico de cada variable se presenta en la sección de análisis exploratorio.

El volumen de registros por año es desigual: 8.120 en 2022 y 20.745 en 2025, frente a más de 27.000 en 2023 y 2024, porque 2022 y 2025 son años parciales. Por eso el análisis temporal se hace sobre el índice mensual y no sobre totales anuales.

5. Procesamiento y Calidad de Datos (ETL)

El dataset no tenía valores nulos ni duplicados, pero sí tres problemas de calidad que impedían analizarlo directamente: los precios venían como texto con separador de miles, las fechas como texto en español y la columna Mercados incluía el nombre de la ciudad. Para cada problema se escribió una función de transformación:

transform_price_to_float

Los precios venían como texto con comas de separación de miles, lo que impedía cualquier operación aritmética. La función recorre las columnas de NUMERIC_COLUMNS, quita la coma y convierte el valor a float. Sin esta conversión no se puede calcular ninguna estadística sobre los precios.

transform_str_date_to_date

Las fechas venían como texto en español (por ejemplo, "lunes, 3 de enero de 2022"). La función quita el día de la semana, separa los componentes y usa el diccionario MONTHS_MAPPING para reemplazar el nombre del mes por su número. Luego convierte el resultado a datetime, lo que habilita el análisis temporal.

remove_city_from_market

La columna Mercados repetía el nombre de la ciudad junto al del establecimiento (por ejemplo, "Pereira, Mercasa"), dato que ya está en la columna Ciudad. La función separa ambos y deja solo el nombre del mercado, evitando información duplicada.

clean_data

Encadena las tres transformaciones anteriores con el método pipe de pandas. Agrupar la limpieza en una sola función hace el flujo más legible y fácil de mantener.

6. Enriquecimiento y Generación de Métricas Analíticas

El valor analítico del proyecto está en la creación de columnas derivadas que permiten comparaciones entre diferentes clases de productos. Este proceso es coordinado por la función extend_data, que integra los siguientes componentes:

- **price_variation_range:** Calcula la diferencia absoluta ($\text{Precio_máximo} - \text{Precio_mínimo}$). Provee una medida inicial de la dispersión de precios en un mismo punto de registro.
- **price_variation_percentage:** se calcula como $(\text{price_variation_range} / \text{Precio_medio}) * 100$. Al ser un porcentaje, normaliza la variación y permite comparar en la misma escala la inestabilidad de un producto barato (por ejemplo, cilantro) frente a uno caro (por ejemplo, carne de res).

- **Componentes temporales:** A través de la función `add_date_parts`, se generan las columnas `anio`, `mes` y `anio_mes`. Estas permiten realizar agrupaciones cronológicas para detectar estacionalidad y tendencias interanuales en el costo de vida.

7. Análisis Exploratorio de Datos

Una vez limpio y con las nuevas columnas en el dataset, el programa genera el resumen estadístico de cada grupo de variables mediante las funciones `describe_numerical_columns`, `describe_categorical_columns` y `describe_added_columns` de `cli.py`. Las siguientes tablas reproducen esa salida e interpretan lo que muestran.

Resumen estadístico de las variables numéricas

Estadística	Precio_mínimo	Precio_máximo	Precio_medio
Registros	83.813	83.813	83.813
Media	9.177,30	9.884,91	9.524,89
Desv. estándar	10.757,15	11.380,18	11.038,73
Mínimo	130,00	333,00	333,00
Percentil 25	2.064,00	2.500,00	2.308,00
Mediana	4.200,00	4.800,00	4.493,00
Percentil 75	13.333,00	14.000,00	13.687,00
Máximo	222.200,00	245.000,00	234.733,00

Tabla 1. Salida de `describe()` sobre las columnas de precio, después de la limpieza.

Las tres columnas de precio están sesgadas a la derecha: la media del precio medio (9.524,89 COP) es más del doble de la mediana (4.493) y la desviación estándar (11.038,73) supera a la media. Eso indica una cola larga de productos caros: el máximo llega a 234.733 COP frente a un mínimo de 333. La mitad central de los registros (entre el percentil 25 y el 75) se ubica entre 2.308 y 13.687 COP. Esta dispersión es la razón por la que el análisis temporal y entre ciudades se hace con un índice de precios y no con un promedio normal, que quedaría dominado por unos pocos productos caros.

Resumen de las variables categóricas

Estadística	Productos	Mercados	Categoría	Ciudad
Registros	83.813	83.813	83.813	83.813
Valores únicos	213	7	8	4
Más frecuente	Banano criollo	Plaza La 21	Frutas	Pereira

Frecuencia del más frecuente	942	19.693	22.336	28.303
-------------------------------------	-----	--------	--------	--------

Tabla 2. Salida de *describe()* sobre las columnas categóricas.

El dataset cubre 213 productos distintos, 8 categorías y 4 ciudades, tras quitar la ciudad de la columna Mercados quedan 7 mercados. El producto con más registros es el banano criollo (942), el mercado más frecuente es Plaza La 21 y la categoría con más mediciones es Frutas (22.336 registros). La ciudad con más registros es Pereira.

Distribución de registros por ciudad y por categoría

Ciudad	Registros
Pereira	28.303
Ibagué	19.693
Armenia	18.559
Manizales	17.258

Tabla 3. Registros por ciudad (*value_counts*).

Categoría	Registros
Frutas	22.336
Verduras y Hortalizas	17.556
Carnes	13.479
Procesados	10.907
Tubérculos, Raíces y Plátanos	7.382
Granos y Cereales	4.658
Huevos y Lácteos	3.993
Pescados	3.502

Tabla 4. Registros por categoría (*value_counts*).

Los registros no se reparten por igual entre grupos: Pereira concentra cerca del 34% de las mediciones (28.303 de 83.813) y Frutas alrededor del 27%. Este muestreo desigual por ciudad y por categoría es la razón por la que las comparaciones entre grupos se hacen con índices normalizados y medianas, y no con promedios o conteos crudos, que estarían influidos por cuántas veces se midió cada grupo.

Resumen de las columnas derivadas

Estadística	price_variation_range (COP)	price_variation_percentage (%)
Registros	83.813	83.813
Media	707,60	10,89
Desv. estándar	1.545,51	11,76
Mínimo	0,00	0,00
Percentil 25	120,00	2,71
Mediana	400,00	7,32
Percentil 75	900,00	15,52
Máximo	44.222,00	151,31

Tabla 5. Salida de describe() sobre las columnas derivadas.

La variación absoluta entre el precio mínimo y el máximo de cada registro (price_variation_range) tiene una media de 707,60 COP, pero una mediana de 400, otra vez sesgada a la derecha. La variación porcentual (price_variation_percentage) tiene una mediana de 7,32% y el 75% de los registros queda por debajo de 15,52%, con un máximo de 151,31%: esos valores extremos son los atípicos que se ocultan visualmente en el boxplot de la sección de visualizaciones. El mínimo de 0% confirma que en muchos registros el precio mínimo y el máximo coinciden.

8. Visualización e Interpretación de Resultados

El análisis comparativo entre grupos se concentra en tres visualizaciones interpretadas: la evolución temporal del nivel de precios, la comparación del nivel de precios entre las cuatro ciudades y la comparación de la volatilidad entre las ocho categorías de producto. Cada una responde a una pregunta y documenta la decisión de método detrás del gráfico.

8.1 Evolución Temporal del Índice de Precios

Archivo: figures/01_indice_precios_evolucion.png. La pregunta es cómo evolucionó el precio de la canasta familiar entre septiembre de 2022 y septiembre de 2025. No se usó el promedio del precio medio: con 213 productos de precios muy dispares (de 333 a 234.733 COP), el promedio queda dominado por los productos caros y cambia según qué productos se midieron cada mes, lo que produce variaciones que no reflejan cambios reales de precio. En su lugar se construyó un índice de precios relativos con base 100 en septiembre de 2022: cada producto se

compara contra su propio precio del mes base y luego se promedian los relativos. El mes base contiene 201 de los 213 productos (94% de cobertura).




Figura 1. Índice de precios de la canasta familiar (base 100 = septiembre 2022).

El índice parte de 100 en septiembre de 2022 y cierra en 120,9 en septiembre de 2025, una inflación acumulada cercana al 21% en el período, con un máximo de 121,7. La trayectoria no es lineal: sube con fuerza hasta inicios de 2023, corrige el precio hasta mitad de ese año, sube y baja sin tendencia clara durante 2023 y 2024, y vuelve a subir de forma sostenida en 2025 hasta el máximo de la serie. La forma de esta curva coincide con la evolución de la inflación de alimentos en Colombia que reportan las fuentes oficiales, como se detalla a continuación.

Como el dataset corresponde a productos de la canasta familiar, la referencia es la inflación de alimentos y no solo el IPC total; las tres fases del índice coinciden con lo que reportan el DANE y el Banco de la República. La subida fuerte entre septiembre de 2022 y comienzos de 2023 coincide con el pico inflacionario del país: la división Alimentos y bebidas no alcohólicas alcanzó una variación anual de 26,18% en enero de 2023 y el IPC total llegó a 13,34% en marzo de 2023, la cifra más alta desde 1999. La corrección y la oscilación de 2023 y 2024 coinciden con la desaceleración posterior: el IPC total cerró 2023 en 9,28% y 2024 en 5,20%, y la inflación de alimentos bajó hasta 3,31% al cierre de 2024. La nueva subida sostenida de 2025 coincide con la subida de los alimentos, que volvieron a 5,07% al cierre de ese año, impulsados sobre todo por la carne de res (9,55%) y el café (52,07%), mientras la papa (-24,61%), el arroz (-6,68%) y los huevos (-2,51%) bajaron. El encarecimiento acumulado cercano al 21% que

mide el índice propio y su forma no lineal son coherentes con el ciclo de inflación de alimentos documentado oficialmente. El índice no demuestra causas, pero su trayectoria es consistente con esa evolución.

Fuentes: DANE — Boletines del IPC de enero de 2023, diciembre de 2023 y diciembre de 2025 (dane.gov.co); Banco de la República (banrep.gov.co); Portafolio, “Inflación de marzo de 2023 fue de 13,34%” (portafolio.co, 2023).

8.2 Comparación entre Ciudades

Archivo: [figures/02_indice_precios_ciudad.png](#). La pregunta es qué ciudad presenta el nivel de precios más alto sobre una canasta comparable. Comparar el precio promedio por ciudad sería dar un dato malo, porque cada ciudad registra una mezcla distinta de productos. Para una comparación válida se trabajó solo con los 48 productos presentes en las cuatro ciudades, para cada uno se calculó su precio relativo respecto a su media entre ciudades y se tomó la mediana por ciudad (índice donde 100 = promedio regional).




Figura 2. Índice de nivel de precios por ciudad sobre 48 productos comunes.

Manizales 103,6 (la más cara), Pereira 101,1, Armenia 99,4 e Ibagué 96,8 (la más barata). La diferencia entre la más cara y la más barata es de unos 7 p.p, un rango moderado.

Este resultado contradice el promedio, según el cual Ibagué aparecía como la ciudad más cara (10.713 COP de promedio frente a 8.670 de Armenia). La diferencia se explica por la composición: Ibagué registra más productos de precio alto, lo que inflaba su promedio. Al

comparar producto contra producto, Ibagué era en realidad la más económica. El caso muestra por qué un promedio sobre productos heterogéneos puede invertir una conclusión.

Hay que aclarar que la comparación se basa en 48 de 213 productos. Cada ciudad registra además productos locales (entre 113 y 141 por ciudad) que quedan fuera.

8.3 Volatilidad de Precios por Categoría

Archivo: figures/03_volatilidad_categoria.png. La pregunta es qué categorías presentan precios más volátiles dentro de un mismo registro de mercado. Se usó la columna derivada `price_variation_percentage`, que ya es un porcentaje por lo que es comparable entre productos de distintos niveles de precio. Se representó como diagrama de cajas por categoría, ordenado por la mediana.




Figura 3. Volatilidad de precios por categoría (`price_variation_percentage`).

Verduras y Hortalizas 15,5%, Frutas 11,4%, Tubérculos, Raíces y Plátanos 11,3%, Carnes 4,3%, Pescados 3,8%, Procesados 3,3%, Granos y Cereales 3,1%, Huevos y Lácteos 0,0%. Los productos frescos y perecederos son los más volátiles, este patrón es coherente con su carácter estacional, los procesados, granos y lácteos son los más estables. La mediana de 0,0% en Huevos y Lácteos indica que en más de la mitad de los registros el precio mínimo y el máximo coinciden.

Por otro lado, para que las cajas fueran legibles se ocultaron del gráfico los valores atípicos extremos (cerca del 1% de los registros, con variaciones de hasta 150%). Se ocultaron solo de manera visual, los valores siguen en los datos.

9. Respuestas a las preguntas analíticas

Las cinco preguntas que orientaron el análisis se responden con los resultados obtenidos en las secciones anteriores.

Pregunta	Respuesta y resultado
¿Cómo evoluciona el índice de precios de los productos de la canasta familiar en el tiempo?	El índice sube a 120,9 en septiembre de 2025: una inflación acumulada cercana al 21%, con trayectoria no lineal (fuerte subida hasta inicios de 2023, corrección y variación en 2023–2024, y nueva subida en 2025 hasta el máximo de 121,7). Figura 1.
¿Qué ciudades del Eje Cafetero presentan mayores niveles de precios?	Sobre 48 productos comunes, Manizales es la más cara (índice 103,6) e Ibagué la más barata (96,8); rango de unos 7 puntos. El resultado invierte el promedio simple, que situaba a Ibagué como la más cara. Figura 2.
¿Qué categorías de productos muestran mayor variabilidad o volatilidad en sus precios?	Verduras y Hortalizas es la más volátil (mediana 15,5%), seguida de Frutas (11,4%) y Tubérculos, Raíces y Plátanos (11,3%). Huevos y Lácteos es la más estable (0,0%). Figura 3.
¿Qué tan amplia es la diferencia entre los precios mínimos y máximos reportados dentro de un mismo registro?	En valor absoluto (<code>price_variation_range</code>), la mediana es 400 COP y la media 707,60. En términos relativos (<code>price_variation_percentage</code>), la mediana es 7,32%, el 75% de los registros queda por debajo de 15,52% y el máximo llega a 151,31%. Tabla 5.
¿Qué utilidad ofrecen las columnas derivadas para comparar productos, ciudades y categorías en términos de variabilidad de precios?	<code>price_variation_percentage</code> normaliza la variación y permite comparar en la misma escala productos baratos y caros; <code>anio</code> , <code>mes</code> y <code>anio_mes</code> habilitan la agregación temporal. Sin estas columnas no serían posibles ni el

	índice temporal (Figura 1) ni la comparación de volatilidad entre categorías (Figura 3).
--	--

Tabla 6. Respuestas a las preguntas analíticas con su resultado.

10. Uso de Inteligencia Artificial Generativa

El desarrollo se apoyó en herramientas de inteligencia artificial generativa, para la ilustración del flujo se usó Napkin AI. El aporte más útil de la herramienta no fue escribir código, sino señalar errores de método antes de programar. Antes de escribir el código de cada gráfico se verificó el método sobre los datos reales (cobertura del mes base, número de productos comunes, distribución de la volatilidad), para no programar sobre supuestos. En el gráfico de volatilidad se decidió ocultar los valores extremos solo de forma visual, dejándolo documentado en lugar de eliminarlos. La dirección de las decisiones, la elección del enfoque de cada gráfico, la revisión de cada figura y la validación de los resultados se hicieron en equipo. La herramienta funcionó como apoyo de ejecución y de control de método. La lección práctica es que la IA es útil en la medida en que quien la dirige sabe qué pedir y puede reconocer cuándo una respuesta es incorrecta.

11. Conclusiones

- Arquitectura por modulo: separar la lógica en archivos como pipeline.py y config.py facilitó el mantenimiento y permitiría adaptar el programa a otros datasets con pocos cambios.
- Métricas sobre valores absolutos: trabajar con índices y porcentajes en lugar de solo promedios cambió las conclusiones. En el período, la canasta acumuló una inflación cercana al 21%, sobre una canasta comparable Manizales resultó la ciudad más cara e Ibagué la más barata, al revés de lo que sugería solo el promedio, y la mayor volatilidad se concentró en los productos frescos (verduras, frutas y tubérculos).
- El dataset no tenía nulos ni duplicados, pero sí precios y fechas como texto. Corregir esos formatos fue el paso que hizo posible todo el análisis posterior, sin esa limpieza ninguna estadística habría sido confiable.
- La creación de columnas derivadas permitió obtener una visión más completa del comportamiento de los precios. Gracias a métricas como la variación absoluta y porcentual, fue posible identificar diferencias importantes entre categorías de productos

y reconocer cuáles presentan mayores niveles de volatilidad, aportando información que no era evidente en los datos originales.

12. Referencias

- Portal de Datos Abiertos de Colombia. Histórico de Precios Productos de la Canasta Familiar RAP Eje Cafetero. https://www.datos.gov.co/Agricultura-y-Desarrollo-Rural/Historico-de-Precios-Productos-de-la-Canasta-Famil/gdqq-rry2/about_data
- DANE. Índice de Precios al Consumidor (IPC). Boletines de enero de 2023, diciembre de 2023 y diciembre de 2025. <https://www.dane.gov.co/index.php/estadisticas-por-tema/precios-y-costos/indice-de-precios-al-consumidor-ipc>
- Banco de la República de Colombia. Índice de precios al consumidor (IPC). <https://www.banrep.gov.co>
- Portafolio (2023). Inflación en Colombia para marzo de 2023 fue de 13,34%. <https://www.portafolio.co/economia/finanzas/inflacion-en-colombia-para-marzo-de-2023-fue-de-13-34-dane-580982>
- BBVA Research (2026). Colombia: la inflación cerró 2025 en 5,10%. <https://www.bbvarsearch.com/en/publicaciones/colombia-inflation-ended-2025-at-510-virtually-unchanged-from-the-previous-year/>